算法大作业报告

小组成员:

王明硕 任勇宁 刘一辰

一、作业要求:

查询图中两个顶点之间的最短距离的常见的方法有 BFS, Di jkstra 等。这两种方法通过**实时遍历**图上的点和边来获取两点之间的最短距离,因此在规模较大的图上用时较长。为解决这一问题,2-hop 索引方法【1】被提出,其核心思想是**事先计算一部分顶点之间的距离**,将其**储存在索引之中**,并在查询最短距离时,利用**最短路径的最优子结构特性**,使用两个储存的最短距离**组合出来需要查询的最短距离**(比如,储存 s-h、h-t 的最短距离,其中 h 在 s-t 的最短路径上,则 s-h、h-t 的最短距离之和为 s-t 的最短距离)。

在现实场景下,社交网络、知识图谱等图的结构会不断变化。当**图的结构发生变化**时,如何高效地**维护/修改 2-hop 索引**,以便使用 2-hop 索引准确地查询变化后的图中的最短距离,具有重要的现实作用。【2】中描述了前沿的 **2-hop 索引动态维护算法**。本次大作业将给出上述算法的不完整 C++代码,要求同学们补全这些代码,使得相应的测试程序可以无 bug 地运行。

二、论文阅读与伪代码分析:

(一) 论文一:

论文一主要介绍了引入剪枝操作的BFS,其使用的为无权无向图,主要是介绍了"2-hop标签"的概念以及作用,来为论文二做铺垫。

这里提到了用到的符号。

Notation	Description
G = (V, E)	A graph
n	Number of vertices in graph G
m	Number of edges in graph G
$N_G(v)$	Neighbors of vertex v in graph G
$d_G(u,v)$	Distance between vertex u and v in graph G
B (21, 21)	Set of all the vertices on the shortest paths
$P_G(u,v)$	between vertex u and v in graph G

由于背景为无权图,一定满足三角不等式,当 v 出现在 s 和 t 的最短路径上时(即 v 在集合 P 中),不等式取等号。

$$d_G(s,t) \le d_G(s,v) + d_G(v,t), \tag{1}$$

$$d_G(s,t) \ge |d_G(s,v) - d_G(v,t)|. \tag{2}$$

We define $P_G(s,t) \subseteq V$ as the set of all vertices on the shortest paths between vertices s and t. In other words,

$$P_G(s,t) = \{ v \in V \mid d_G(s,v) + d_G(v,t) = d_G(s,t) \}.$$

QUERY 函数是在 L(s) 和 L(t) 的交集中所有的顶点 v,找出最小的距离。根据最短路径最优子结构特性,可以组合出 s 和 t 的最短路径,这也是 2-hop 的核心思想。

QUERY(s, t, L) =

 $\min \left\{ \delta_{vs} + \delta_{vt} \mid (v, \delta_{vs}) \in L(s), (v, \delta_{vt}) \in L(t) \right\}.$

Algorithm 1 Pruned BFS from $v_k \in V$ to create index L'_k .

```
1: procedure PRUNEDBFS(G, v_k, L'_{k-1})
          Q \leftarrow a queue with only one element v_k
         P[v_k] \leftarrow 0 and P[v] \leftarrow \infty for all v \in V(G) \setminus \{v_k\}.
         L'_k[v] \leftarrow L'_{k-1}[v] for all v \in V(G).
while Q is not empty do
 4:
 5:
              Dequeue u from Q.
 6:
              if QUERY(v_k, u, L'_{k-1}) \leq P[u] then
 7:
 8:
                  continue
9:
              L'_{k}[u] \leftarrow L'_{k-1}[u] \cup \{(v_{k}, P[v_{k}])\}
10:
              for all w \in N_G(v) s.t. P[w] = \infty do
                   P[w] \leftarrow P[u] + 1.
                  Enqueue w onto Q.
13:
         return L'_k
```

Algorithm 2 Compute a 2-hop cover index by pruned BFS.

```
1: procedure PREPROCESS(G)

2: L'_0[v] \leftarrow \emptyset for all v \in V(G).

3: for k = 1, 2, ..., n do

4: L'_k \leftarrow \text{PRUNEDBFS}(G, v_k, L'_{k-1})

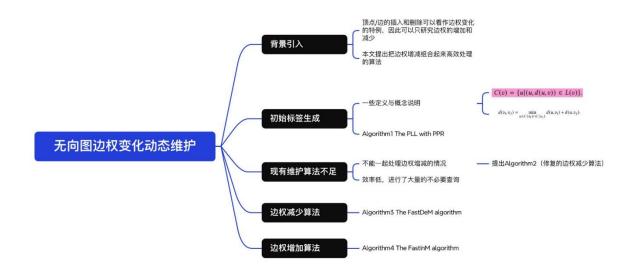
5: return L'_n
```

对伪代码的分析:

主体框架为广度优先搜索,对每个节点执行广度优先搜索,就形成了每个顶点的标签。不同之处在于加入了purn 剪枝操作。具体来说为Algorithm 1的7-9行。如果能用现有标签组合出未求出的最短距离,则进行剪枝。最终该算法能生成每个顶点的二跳标签。

(二)论文二:

论文二的整体框架如下:



下面对主要部分做分析:

1. 初始标签生成部分:

这部分承接了论文一的 2-hop 标签的思想。变化之处在于:一方面把无权图变成了有权图(因此查询最短距离时的主体算法也从 BFS 变成了 Di jkstra),另一方面引入了 PPR 这一结构,便于快速识别受到边权增加影响的标签来提高维护效率。

下面分析伪代码:

Algorithm 1 The PLL algorithm incorporated with PPR

```
Input: a graph G(V, E, w)
                                     Output: L and PPR
 1: Initialize L = PPR = \emptyset
 2: for each sorted vertex u \in V do
       Initialize Q = \emptyset, d(u) = 0, d(v) = NIL for each v \in V \setminus u
 3:
       Insert u into Q with the priority value of d(u)
       while Q \neq \emptyset do
           Pop v out of Q with the priority value of d(v)
 7:
           if r(u) \ge r(v) then
              if Query(u, v, L) \le d(v) then
 8:
                  PPR[v, h_c].push(u), PPR[u, h_c].push(v); Continue to Line 5
               Insert (u, d(v)) into L(v)
10:
               for each vertex x \in N(v) do
11:
                  if d(x) == NIL then
13.
                      Insert x into Q with the priority value of d(x) = d(v) + w(x, v)
                   else if d(x) > d(v) + w(x, v) then
14:
                      Update x in Q with the priority value of d(x) = d(v) + w(x, v)
15:
16: Return L and PPR
```

主体部分是 Di jkstra 算法(line 2: 对每个顶点用一次)。这里遍历顺序为顶点度大的先遍历(line 2),因为度大的更可能出现在其他顶点的最短路径上(成为 hub),这样后续便于剪枝来提高效率。剔除 Di jkstra 的主体框架后,我们看到创新的主要在 8-10 行:这里是生成 L 和 PPR 的部分,在 query 结果小于等于 d 时(hc 在 u 和 v 的最短路径上),更新 PPR,不更新 L;否则更新 L(利用 Di jkstra 查询出的距离,而不是 2-hop)。这里之所以这样操作是因为 query 出的最短距离不仅包含了距离信息,还包含了路径上的顶点信息,利用 PPR 就可以把路径上的顶点信息保存下来,这是 L 做不到的。第 7 行的条件可以防止重复查询(因为遍历时是按照度的大小遍历的)。

2.边权减少维护算法:

```
Algorithm 3 The FastDeM algorithm

Input: the updated graph G(V, E, w), L, PPR, (a, b) // w_0 > w_1
Output: the maintained L and PPR

1: CL^c = \emptyset; Conduct Lines 2-17 of Algorithm 2 without updating L
2: DIFFUSE(CL^c)
3: Return L and PPR

Procedure DIFFUSE(CL^c)
4: for each (u, v, d_u) \in CL^c do
5: Dis[u] = d_u, Dis[s] = -1 \forall s \in V \setminus u, Q = \{(u \mid d_u)\}
6: while Q \neq \emptyset do
7: Pop(x \mid d_x) out of Q, L(x)[v] = d_x
8: for each x_0 \in N(x) such that r(v) > r(x_0) do
9: if Dis[x_n] = -1 then Dis[x_n] = Query(x_n, v, L)
10: if Dis[x_n] = -1 then Dis[x_n] = Query(x_n, v, L)
11: Dis[x_n] = d_x + w(x_n, x) then
11: Dis[x_n] = d_x + w(x_n, x) insert (or update) (x_n \mid Dis[x_n]) \in Q
12: else
13: if v \in C(x_n) \otimes \min\{L(x_n)[v], Q(x_n)\} > d_{new} = d_x + w(x_n, x) then
14: Insert (or update) (x_n \mid d_{new}) \in Q
15: PPR[x_n, h_c], push(v), PPR[v, h_c], push(x_n)
```

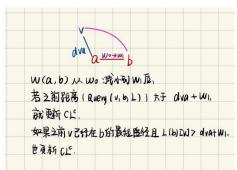
```
3:
         if r(v) \ge r(b) then
 4:
              if Query(v, b, L) > d_{va} + w_1 \text{ then } / / w(a, b) = w_1
                  \frac{L(b)[v] = d_{va} + w_1}{L(b)[v]} \cdot CL^c \cdot push((b, v, d_{va} + w_1))
                  if v \in C(b) \& L(b)[v] > d_{va} + w_1 then \frac{L(b)[v] - d_{va} + w_1}{d_{va} + w_1}, CL^c.push((b, v, d_{va} + w_1))
 8:
                  PPR[b,h_c].push(v), PPR[v,h_c].push(b)
 9:
10: for each label (v,d_{vb})\in L(b)do
11:
         if r(v) \ge r(a) then
              if Query(v, a, L) > d_{vb} + w_1 then
12:
13:
                  L(a)[v] = d_{vb} + w_1, CL^c.push((a, v, d_{vb} + w_1))
14:
                   if v \in C(a) \& L(a)[v] > d_{vb} + w_1 then

L(a)[v] = d_{vb} + w_1, CL^c.push((a, v, d_{vb} + w_1))
15:
                   PPR[a, h_c].push(v), PPR[v, h_c].push(a)
```

算法步骤即 Algorithm 3 的 1-3 行。思想就是,既然 w (a, b) 变化了,就以 a 和 b 为 中心点开始遍历。

先执行算法 2 的 2-17 行(上图给出),但是不更新 L。对 a 和 b 做遍历时是一个对称

的过程。分出 if else 是因为 v 可能在 b 的 label 里也可能不在。对于 v 已经在 L (b) 的情况,还需要更新 PPR。



接下来再执行 DIFFUSE:

该部分更新 L 和 PPR。利用刚刚得到的 CLc 中记录的信息来更新。利用优先队列和距离数组,DIFFUSE 确保所有过时的标签都能通过更新的边直接传播,以便在后续边权重增加时进行进一步的维护。

比如下图, 当 v0 和 v3 的权重从 5 减小到 3, CLc 会存入(v3, v0, 3)。执行 DIFFUSE 时, 一开始队列里是(v3, 3),这样就会把 L(v3)[v0] 更新为 3,即(v0, 3)。

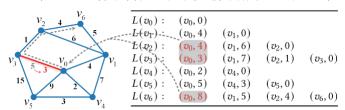


Figure 4: An example of FastDeM.

3. 边权增加算法:

Algorithm 4 The FastInM algorithm

```
Input: the updated graph G(V,E,w), L, PPR, (a,b), w_0 // w_0 < w_1 Output: the maintained L and PPR
 1: AL_1 = AL_2 = AL_3 = \emptyset
2: for each label (v, d_{va}) \in L(a) do
         if r(v) \ge r(b) \& (v, d_{va} + w_0) \in L(b) then AL_1.push((b, v, d_{va} + w_0))
 4: for each label (v, d_{vb}) \in L(b) do

5: if r(v) \ge r(a) \& (v, d_{vb} + w_0) \in L(a) then AL_1.push((a, v, d_{vb} + w_0))
 6: SPREAD_1(AL_1,AL_2), SPREAD_2(AL_2,AL_3), SPREAD_3(AL_3)
7: Return L and PPR
      Procedure SPREAD_1(AL_1, AL_2)
 8: for each (u, v, d') \in AL_1 do 9: Queue = \{(u, d')\}
10:
            while Oueue ≠ 0 do
                Gueue, pop((x, d_X)), L(x)[v] = \infty, AL_2, push((x, v))

for each x_n \in N(x) such that r(v) > r(x_n) do

if (v, d_X + w(x, x_n)) \in L(x_n) then Queue. push((x_n, d_X + w(x, x_n)))
 12:
13:
      Procedure SPREAD2 (AL2, AL3)
14: for each (x, y) \in AL_2 do
15: for each t \in PPR[x, y] \cup y do
16:
                if r(t) > r(x) then
17:
                      d1(x,t) = \min_{x_n \in N(x)} \{ L(x_n)[t] + w(x,x_n) \}
18:
19:
                      if Query(x, t, L) > d1(x, t) then AL_3.push((x, t, d1(x, t))) else PPR[x, h_c].push(t), PPR[t, h_c].push(x)
                 if r(x) > r(t) then
21:
                      d1(t,x) = \min_{t_n \in N(t)} \{ L(t_n)[x] + w(t,t_n) \}
                     if Query(t,x,L) > d1(t,x) then AL_3.push((t,x,d1(t,x))) else PPR[t,h_c].push(x), PPR[x,h_c].push(t)
22:
      Procedure SPREAD3 (AL3)
24: for each (u,v,d_u) \in AL_3 do 25: if Q(u,v,L) \leq d_u then PPR[u,h_c].push(v), PPR[v,h_c].push(u); Continue
26:
27:
            Dis[u] = d_u, Dis[s] = -1 for each s \in V \setminus u, Q = \{(u \mid d_u)\}
           while Q \neq \emptyset do
                 \operatorname{Pop}(x \mid d_X) \text{ out of } Q, L(x)[v] = \min(d_X, L(x)[v])
                for each x_n \in N(x) such that r(v) > r(x_n) do
30:
                      if Dis[x_n] == -1 then Dis[x_n] = Query(x_n, v, L)
                     \begin{array}{l} \text{if } Dis[x_n] > d_X + w(x_n,x) \text{ then} \\ Dis[x_n] = d_X + w(x_n,x); \text{ Insert (or update) } (x_n \mid Dis[x_n]) \in Q \\ \text{else } PPR[x_n,h_c].push(v), PPR[v,h_c].push(x_n) \end{array}
31:
33:
```

下面这段话介绍了该算法的主要思想:

The FastInM **algorithm:** The algorithm inputs the updated graph G(V, E, w), L, PPR, (a, b) and w_0 . First, it initializes three empty sets AL_1 , AL_2 and AL_3 (Line 1). It uses AL_1 to store labels in $L(a) \cup L(b)$ that correspond to paths that pass through (a, b). Based on AL_1 , it finds all labels that correspond to paths that pass through (a, b), and then deactivates these labels, and also uses AL_2 to record these labels. After the deactivation, some originally pruned labels can be newly produced. It uses AL_3 to record these labels, and uses these labels as starting points to generate more labels.

AL1 能记录所有经过(a,b)的路径,停用这些标签并记录到 AL2 中。停用后,之前被 修剪的标签可以重新生成,用 AL3 记录,并且通过这些标签作为起点来生成更多标签。

下图是是整体框架:

先填充 AL1,如果 v 到 b 的最短路径经过 a,存入 AL1;同理,如果 v 到 a 的最短路径经过 b,存入 AL1。这样 AL1 就记录了所有经过 (a,b)的最短路径。spread1 基于 AL1 生成 AL2,spread2 基于 AL2 生成 AL3,spread3 基于 AL3 生成新标签。

```
Input: the updated graph G(V, E, w), L, PPR, (a, b), w_0 // w_0 < w_1 Output: the maintained L and PPR

1: AL_1 = AL_2 = AL_3 = \emptyset

2: for each label (v, d_{va}) \in L(a) do

3: if r(v) \ge r(b) \& (v, d_{va} + w_0) \in L(b) then AL_1.push((b, v, d_{va} + w_0))

4: for each label (v, d_{vb}) \in L(b) do

5: if r(v) \ge r(a) \& (v, d_{vb} + w_0) \in L(a) then AL_1.push((a, v, d_{vb} + w_0))

6: SPREAD_1(AL_1, AL_2), SPREAD_2(AL_2, AL_3), SPREAD_3(AL_3)

7: Return L and PPR
```

下面对三个 spread 的关键点作说明:

```
Procedure SPREAD_{1}(AL_{1},AL_{2})

8: for each (u,v,d') \in AL_{1} do

9: Queue = \{(u,d')\}

10: while Queue \neq \emptyset do

11: Queue.pop((x,d_{x})), L(x)[v] = \infty, AL_{2}.push((x,v))

12: for each x_{n} \in N(x) such that r(v) > r(x_{n}) do

13: if (v,d_{x} + w(x,x_{n})) \in L(x_{n}) then Queue.push((x_{n},d_{x} + w(x,x_{n})))
```

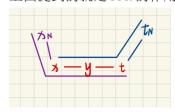
spread1 主要是通过将 L(x)[v]置为无穷来停用与(a, b)相关的标签,并将这些标签存入 AL2(对应于 1 ine 11)。其余操作类似于广搜,实现遍历。

```
Procedure SPREAD_2(AL_2, AL_3)
14: for each (x, y) \in AL_2 do
       for each t \in PPR[x, y] \cup y do
15:
16:
           if r(t) > r(x) then
17:
               d1(x,t) = \min_{x_n \in N(x)} \{ L(x_n)[t] + w(x,x_n) \}
               if Query(x, t, L) > d1(x, t) then AL_3.push((x, t, d1(x, t)))
18:
19:
               else PPR[x, h_c].push(t), PPR[t, h_c].push(x)
20:
           if r(x) > r(t) then
21:
              d1(t,x) = \min_{t_n \in N(t)} \{ L(t_n)[x] + w(t,t_n) \}
22:
               if Query(t, x, L) > d1(t, x) then AL_3.push((t, x, d1(t, x)))
              else PPR[t, h_c].push(x), PPR[x, h_c].push(t)
```

spread2 在找出依赖 L(x)[y] 生成的标签,这些标签需要被重新生成,这个时候就需要用到 PPR。

it enumerates each $t \in PPR[x, y] \cup y$ (Line 15). If $t \in PPR[x, y]$, then either $y \in C(x) \cap C(t)$ is responsible for originally pruning the spread of hub t from a neighbor of x to x (i.e., r(t) > r(x)), or y is responsible for originally pruning the spread of hub x from a neighbor of t to t (i.e., r(x) > r(t)). If t = y (i.e., r(t) > r(x)), then it may be possible to update L(x)[y] by re-spreading hub y from a neighbor of x to x. Based on these analyses, it identifies

上图提到的就是 PPR 的作用原理, 意思大致是下图所画:



```
 \begin{array}{llll} & \text{Procedure } SPREAD_3(AL_3) \\ 24: & \text{ for each } (u, v, d_u) \in AL_3 \text{ do} \\ 25: & & \text{ if } Q(u, v, L) \leq d_u \text{ then } PPR[u, h_c].push(v), PPR[v, h_c].push(u); \text{Continue} \\ 26: & & Dis[u] = d_u, Dis[s] = -1 \text{ for each } s \in V \setminus u, Q = \{(u \mid d_u)\} \\ 27: & & \text{ while } Q \neq \emptyset \text{ do} \\ 28: & & \text{Pop } (x \mid d_x) \text{ out of } Q, L(x)[v] = \min(d_x, L(x)[v]) \\ 29: & & \text{ for each } x_n \in N(x) \text{ such that } r(v) > r(x_n) \text{ do} \\ 30: & & \text{ if } Dis[x_n] = -1 \text{ then } Dis[x_n] = Query(x_n, v, L) \\ 31: & & \text{ if } Dis[x_n] > d_x + w(x_n, x) \text{ then} \\ 32: & & Dis[x_n] = d_x + w(x_n, x) \text{ insert for update) } (x_n \mid Dis[x_n]) \in Q \\ 33: & & \text{ else } PPR[x_n, h_c].push(v), PPR[v, h_c].push(x_n) \\ \end{array}
```

spread3 基本和前面 decrease 算法的 diffuse 一致,有以下两点不同:第一,spread3 首先检查查询的 u 和 v 之间的距离是否不大于 du(第 25 行),因为新生成的标签可能会修剪其他标签的生成;第二,当 Dis [xn] \leq dx +w (xn, x) 时,spread3 不会以 dx + w (xn, x) 的优先级将 xn 的元素插入(或更新)到 Q 中,因为所有过时的标签都已在 spread1 中停用。

三、C++代码补全与正确性测试:

这部分需要补全四个函数,分别对应着伪代码里的 diffuse, spread1、2、3。基本都是直接根据伪代码翻译即可。需要把定义好的变量与结构以及查询函数了解清楚。需要认真阅读已有的代码,学到一些处理技巧,比如判断浮点数相等不能直接用等号。另外,这几段代码的很多操作是可以互相借鉴的,比如 diffuse 与 spread3 基本是一样的。

下面是补全的代码:

DIFFUSE:

```
{
    Q.update(Q.handles[xn.first], node);
    }
    else Q.handles[xn.first]-Q.push(node), exsit[node.vertex]-true;
}
else
{
    auto search_result = search_sorted_two_hop_label(('t)[xn.first]), affected_l.second);
    if(search_result = MAX_VALUE){
        weightTPF min_val = std::min(search_result, Dis[xn.first]);
        if (min_val > newVal);
        node(yn.first, Dis[xn.first]);
        if (exsit[xn.first]);
        if (exsit[xn.first]);
        if (exsit[xn.first]);
        else Q.handles[xn.first], node);
    }
    PPR_insert("PPR, xn.first, dis_vex.second, affected_l.second);
    PPR_insert("PPR, affected_l.second, dis_vex.second, xn.first);
}

delete[] Dis;
}

delete[] Dis;
```

SPREAD1:

SPREAD2:

SPREAD3:

下面来说明 debug 的过程:

为了得到代码具体的行为,我们将图与输入点固定位论文中的实例。我们将generate_new_graph 设置为 0 并且将 simple_iterative_tests. txt 改变为我们根据论文实例定义的图来固定图。通过改变 graph_change_and_label_maintenance 函数中 while 循环内部被注释的 if 部分来模拟论文实例的边权变化。通过 mm. print_L(),

mm. print_PPR()得到 L 以及 PPR 的变化,与论文中实例对比,最终在原图上能够得到正确的答案,并能扩展到更大的随机图上,运行出正确结果。

正确性:最终代码可以跑通,跑几百次可能会出现一次错误,基本可以实现动态维护功能。

四、小组成员分工:

前期: 小组成员共同阅读论文与代码

补全代码: 王明硕主要负责 decrease, 任勇宁和刘一辰主要负责 increase

debug: 主要由任勇宁和刘一辰完成

报告撰写: 主要由王明硕完成

全部工作都在 git 上记录,可见 https://github.com/renyongning/lab